Camping Data Platform

Projet fil rouge — version ESIEE 2026 : concevoir la plateforme de données

Software Factory · Valérie Monfort, Dominique Jorge · sujet v5 du 10/10/2026 — urbanisme, architecture Databricks, modélisation Hackolade, données personnelles et consentement

Caractéristique	Valeur
Public	Dernière année du cycle ingénieur
Équipes	2 étudiants
Votre rôle	Une équipe de conception : vous concevez la plateforme, vous ne la construisez pas dans l'intégralité
Plateforme cible	**Databricks** : l'architecture de référence vous est donnée (section 3) ; vous la comprendrez, la décrirez et la justifierez
Livrable	Un dossier de conception, la cartographie **MEGA** AS IS et TO BE, les modèles **Hackolade** (polyglot et Databricks), le notebook SQL qui crée les tables, les schémas C4
Calendrier	4 sprints = 4 séances, puis une journée projet ; dossier à rendre le **mercredi 4 novembre avant midi**
Évaluation	Dossier + soutenance de 15 minutes le **jeudi 5 novembre**
Deux niveaux	SOCLE (obligatoire) : un socle complet et correct vaut jusqu'à 14/20. AVANCÉ (facultatif) : jusqu'à +6 points

1. Le client et sa demande

Les Pins d'Argent est un groupe familial de quatre campings sur la côte atlantique, avec 950 emplacements : nus, mobil-homes et premium. Environ 80 % du chiffre d'affaires se fait en neuf semaines d'été.

Aujourd'hui (AS IS), le SI est constitué de deux systèmes qui ne se parlent pas :

- **Du PMS,** logiciel de réservation (base PostgreSQL) : clients, séjours, tarifs, canaux de vente ;
- **Des exports des agences en ligne (OTA) :** un fichier par jour (Booking, Campings.com…).

Les responsables de la société souhaitent :

- Avoir la maîtrise de leur SI et de ses évolutions
- Mettre en place une démarche méthodologique claire
- Mettre en place un système **d'objets connectés :** bornes électriques, compteurs d'eau, barrière à badge, capteur de la piscine
- Collecter les données issues des objets connectés pour mettre intégrer à la facturation
- Faire communiquer PMS, OTA et Les données des objets connectés

D'autre part, la direction **pilote sur tableur**, en fin de saison : trop tard pour agir !

Elle demande une plateforme de données qui publie quatre Data Products :

Data product	Ce qu'il contient	Pour qui	La question à laquelle il répond
dp_occupation_yield	Taux d'occupation par nuit, chiffre d'affaires, canaux de vente	Direction commerciale	« Combien d'emplacements étaient occupés hier soir, et à quel prix ? »
dp_conso_anomalies	Consommation d'électricité et d'eau par emplacement et par heure, alertes	Services techniques	« Y a-t-il une fuite quelque part ce matin ? »
dp_taxe_sejour	Base de la taxe de séjour par commune et par mois	Comptabilité	« Combien dois-je reverser à la commune pour août ? »

dp_profil_clientele	Profil de la clientèle : âge, composition du groupe, pays	Marketing	« Qui sont nos clients, et qui viser l'an prochain ? »

Le quatrième data product touche aux données personnelles des clients. Il n'est possible que si le client a donné son consentement, et la plateforme doit savoir le prouver et le tracer (section 6).

Votre mission : concevoir cette plateforme. Comprendre l'existant, définir le besoin, modéliser les processus et les données, décrire l'architecture cible en partant de l'architecture de référence, en intégrant l'IA, l'éthique et la sécurité. ***Aucun code n'est demandé au niveau socle.***

2. Ce qui vous est fourni

- l'architecture de référence sur Databricks, son vocabulaire et le nom de chaque table (section 3) ;
- le modèle polyglot de départ dans Hackolade, Camping_polyglot.json (8 entités, leurs clés et leurs relations), et sa documentation PDF (section 4) ;
- le schéma de la base de réservation (annexe A) et le format de l'export OTA (annexe B) ;
- la description des objets connectés et le format de leurs relevés (annexe C), les règles métier (annexe D) ;
- un glossaire (annexe E) et des gabarits à remplir (annexe F) ;
- le format de la fiche client du PMS, du journal des consentements et du référentiel des finalités (annexe H) ;
- pour le niveau avancé : un jeu de données d'exemple (8 fichiers CSV : 12 emplacements, 16 séjours, 3 réservations OTA, 132 relevés de compteurs, 18 fiches clients, 25 choix de consentement, 5 finalités ; fin août – début septembre) et un guide pas à pas sur Databricks Free Edition, gratuit (annexe G). Toutes les personnes du jeu de données sont fictives.

3. L'architecture cible de référence : un lakehouse sur Databricks

Pour que toutes les équipes partent du même point, l'architecture cible vous est donnée. Votre travail n'est pas de l'inventer : c'est de la comprendre, de la décrire avec vos propres modèles (C4, Hackolade), de la justifier et de dire ce que vous changeriez.

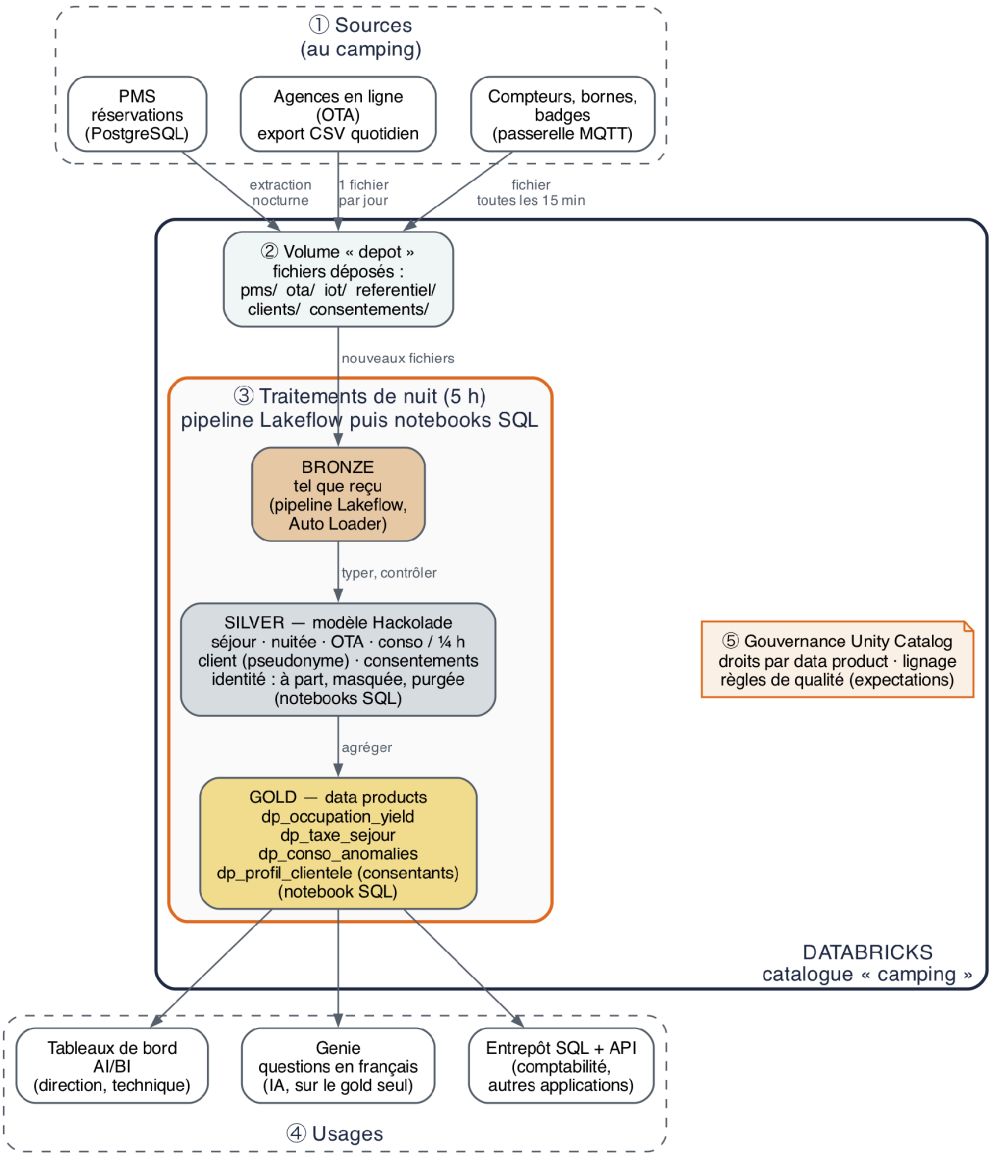


Figure 1 — Architecture de référence. Les données vont toujours dans le même sens : sources → dépôt → bronze → silver → gold → usages.

3.1 Les cinq briques, en une phrase chacune

N°	Brique	Ce qu'elle fait	Sur Databricks	Équivalent ailleurs
①	Sources	Les systèmes existants du camping ; on ne les modifie pas	—	—
②	Dépôt	Reçoit les fichiers tels quels, un dossier par source	Volume Unity Catalog	Un dossier S3 ou Azure
③	Traitements de nuit	Charge le bronze, puis remplit silver et gold et vérifie la qualité	Pipeline Lakeflow (bronze), notebooks SQL (silver, gold), Job	dbt + Airflow
④	Usages	Tableaux de bord, questions en français, accès SQL pour les autres applications	Tableaux de bord AI/BI, Genie, entrepôt SQL	Power BI, Metabase
⑤	Gouvernance	Qui voit quoi ; d'où vient chaque chiffre ; règles de qualité	Unity Catalog	Collibra, Purview

Pourquoi Databricks ? C'est une plateforme très répandue en entreprise, elle réunit les cinq briques au même endroit (moins d'outils à apprendre) et elle existe en version gratuite pour les étudiants (Free Edition).

3.2 Le vocabulaire Databricks

Terme	En français courant
Lakehouse	Une plateforme qui garde les fichiers bruts et les tables propres au même endroit, avec les mêmes droits.
Unity Catalog	Le catalogue de Databricks : il range les données (catalogue > schéma > table), dit qui a le droit de voir quoi, et retient d'où vient chaque table (lignage).
Catalogue, schéma, table	Trois niveaux de rangement, comme armoire, tiroir, dossier. Ici : catalogue camping, schémas bronze, silver, gold.
Volume	Un dossier de fichiers géré par Unity Catalog. Les sources y déposent leurs fichiers.
Delta	Le format des tables de Databricks : il garde l'historique des versions et supporte les mises à jour.
Auto Loader	Le mécanisme qui charge seulement les nouveaux fichiers arrivés dans le volume.
Pipeline Lakeflow	Une suite de requêtes SQL déclarées une fois ; Databricks calcule l'ordre d'exécution et affiche le graphe. Ici, il charge le bronze.
Notebook SQL	Une page de cellules SQL que l'on exécute une à une ou d'un coup. Ici : créer les tables (DDL issu de Hackolade), les charger, les contrôler.
DDL	Data Definition Language : les ordres SQL qui créent les tables (CREATE TABLE, ALTER TABLE). Hackolade les écrit à partir du modèle.
Contrainte CHECK	Une règle portée par la table elle-même (« départ après arrivée ») : Databricks refuse toute ligne qui ne la respecte pas.
Expectation	Une règle de qualité attachée à une table (« départ après arrivée »). En cas d'échec : garder la ligne, l'écarter, ou tout arrêter.
Vue matérialisée	Une table calculée à partir d'autres tables et recalculée à chaque passage du pipeline.
Job	Une tâche programmée (« chaque nuit à 5 h ») qui lance l'extraction, le pipeline bronze puis les notebooks.
Entrepôt SQL (SQL warehouse)	La puissance de calcul qui répond aux requêtes des tableaux de bord et des applications.
Genie	Un assistant d'IA qui répond en français à des questions sur des tables choisies (« quel taux d'occupation le 31 août ? »).
Masque de colonne	Une fonction attachée à une colonne : selon la personne qui lit, la valeur s'affiche ou est remplacée par « *** masqué *** ».
Étiquette (tag)	Un mot-clé posé sur une table ou une colonne (ici dcp = donnée à caractère personnel) ; on peut ensuite retrouver toutes les colonnes personnelles d'un coup.
VACUUM	La commande qui supprime pour de bon les anciennes versions d'une table Delta. Sans elle, une ligne effacée reste lisible dans l'historique.

3.3 Le nom de chaque table (imposé)

Tout est rangé dans le catalogue « camping ». Utilisez exactement ces noms dans vos modèles : on doit pouvoir passer de votre modèle Hackolade à la plateforme sans traduction.

Schéma	Table(s)	Contenu
bronze	sejours_pms, export_ota, emplacements, campings, releves_compteurs, clients_pms, consentements, finalites	Une table par fichier reçu, tout en texte, avec le nom du fichier d'origine et l'heure de chargement. On ne corrige rien. Créées par le pipeline Lakeflow.
silver	camping, categorie, emplacement, canal, client	Les référentiels. Le client n'y est connu que par sa référence pseudonymisée, son année de naissance et son pays.
silver	client_identite, consentement, finalite_traitement (à ajouter)	L'identité du client, à part et protégée ; le journal de ses consentements ; les finalités, leur base légale et leur durée de conservation (section 6).
silver	sejour	Les séjours valides ; la contrainte « départ après arrivée » refuse les autres.
silver	reservation_ota	Chaque réservation OTA, rapprochée du séjour du PMS quand il existe (doublon).
silver	releve_compteur	Les relevés des compteurs, typés.
silver	nuitee (à ajouter)	Une ligne par séjour et par nuit. C'est la table centrale.
silver	sejour_rejete, conso_quart_heure (avancé)	Les séjours écartés avec leur motif ; la consommation de chaque quart d'heure.
gold	dp_occupation_yield	Une ligne par nuit, par camping et par catégorie : taux d'occupation, chiffre d'affaires, part du direct.

gold	dp_taxe_sejour	Une ligne par commune et par mois : nuitées d'adultes, tarif, montant à reverser.
gold	dp_conso_anomalies	Une ligne par emplacement et par heure : kWh, litres, remise à zéro, fuite probable, emplacement occupé ou non.
gold	dp_profil_clientele	Une ligne par mois, tranche d'âge, type de groupe et pays : clients, séjours, nuitées, chiffre d'affaires. Seulement les clients qui ont accepté les statistiques.

3.4 Une nuit sur la plateforme

Heure	Ce qui se passe	Brique
Toute la nuit	Les compteurs envoient un relevé toutes les 15 minutes ; la passerelle les dépose dans iot/	① → ②
2 h	L'export OTA de la veille arrive dans ota/	① → ②
4 h 30	Le job copie les tables du PMS dans pms/	① → ②
5 h	Le job lance le pipeline Lakeflow, qui charge les nouveaux fichiers dans le bronze ; puis le notebook 02 remplit silver et gold	③
5 h 15	Le notebook 04 efface les données personnelles arrivées au bout de leur durée de conservation, en silver ET en bronze	③ ⑤
5 h 20	Le notebook 03 contrôle les résultats. Les contraintes CHECK ont déjà refusé les lignes impossibles. Si un contrôle échoue, le job s'arrête, l'équipe data est prévenue et les chiffres de la veille restent affichés	③ ⑤
6 h	Les tableaux de bord sont à jour (exigence de fraîcheur)	④
7 h	Les services techniques voient les alertes de fuite de la nuit	④

3.5 Le parcours d'une donnée : deux séjours suivis de bout en bout

Le séjour S005 : un client arrive le 31 août et part le 1er septembre.

Où	Ce qu'on y voit	Ce qui s'est passé
bronze.sejours_pms	S005 · E05 · DIRECT · « 2025-08-31 » · « 2025-09-01 » · 2 adultes · 0 mineur · « 35.00 » (tout en texte)	Copié tel quel, avec le nom du fichier et l'heure
silver.sejour	La même ligne, avec de vraies dates et un vrai montant	Typé ; la règle « départ après arrivée » est respectée
silver.nuitee	UNE ligne : S005 · E05 · nuit du 31/08 · 35 €	Le séjour est découpé en nuits ; la nuit du départ ne compte pas
gold.dp_occupation_yield	Nuit du 31/08 · Les Dunes · NU : 5 emplacements occupés sur 6	S005 est l'un des cinq
gold.dp_taxe_sejour	Océanville · août : 2 nuitées d'adultes de plus	Compté en août, pas en septembre

Le séjour S016 : départ le 27 août, arrivée le 29 août. Il arrive en bronze, n'entre pas dans silver.sejour (la contrainte dates_coherentes le refuserait), et apparaît dans silver.sejour_rejete avec son motif. Il n'atteint jamais le gold.

3.6 Sécurité et droits

- **L'identité du client est rangée à part.** silver.client ne contient qu'une référence pseudonymisée (client_ref), l'année de naissance et le pays. Le nom et les coordonnées vont dans silver.client_identite : accès restreint, e-mail et téléphone masqués, effacement à la fin de la durée de conservation (section 6).
- **Chaque métier ne voit que son data product.** La direction commerciale lit dp_occupation_yield, les services techniques dp_conso_anomalies, la comptabilité dp_taxe_sejour. Seule l'équipe data voit bronze et silver.
- **Genie ne travaille que sur le gold,** qui ne contient aucune donnée identifiante : seulement des agrégats, et, pour le profil de la clientèle, seulement les clients qui l'ont accepté.

3.7 Ce que vous pouvez changer

Vous pouvez proposer une adaptation (par exemple recevoir les relevés en continu plutôt qu'en fichiers, ou ajouter un data product), à condition de la justifier dans une décision d'architecture (ADR, niveau avancé). Vous ne pouvez pas supprimer les trois couches ni la gouvernance.

4. La modélisation des données avec Hackolade : du polyglot au notebook

Toute la modélisation des données se fait dans Hackolade, en trois niveaux. On ne dessine pas les tables dans Databricks à la main : on les déduit du modèle. Ainsi, le modèle et la plateforme ne peuvent pas diverger.



Figure 2 — La chaîne de modélisation : un modèle logique, un modèle physique dérivé, le script SQL, le notebook, les tables.

Niveau	Ce que c'est	Dans le projet
① Modèle polyglot	Le modèle logique, indépendant de toute technologie : entités, attributs, types simples, clés, relations. Il décrit le métier.	Camping_polyglot.json, fourni avec 8 entités ; vous le complétez
② Modèle cible Databricks	Le modèle physique, dérivé du polyglot : schémas (silver, gold), types Databricks, contraintes CHECK. Il reste relié au polyglot : une modification du polyglot se propage.	Camping_databricks.json, que vous créez par dérivation
③ Script DDL	Les ordres SQL CREATE TABLE et ALTER TABLE, écrits par Hackolade (Forward-Engineering).	silver.sql et gold.sql
④ Notebook SQL	Le script collé dans un notebook Databricks, complété et exécuté.	01_creer_tables_hackolade
⑤ Tables	Les tables vides, avec leurs commentaires et leurs contraintes, dans Unity Catalog.	camping.silver.*, camping.gold.*

4.1 Le modèle polyglot fourni

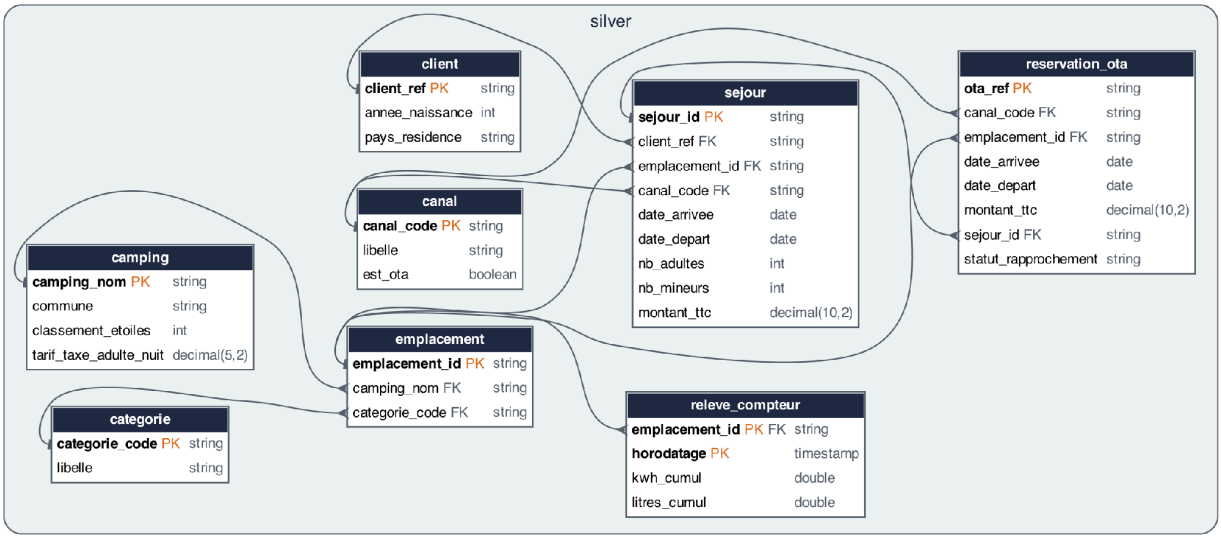


Figure 3 — Camping_polyglot : les 8 entités fournies (PK : clé primaire ; FK : clé étrangère).

Il manque volontairement l'entité la plus importante, la nuitée, et les data products. Il manque aussi l'identité du client et ses consentements (section 6). C'est à vous de les ajouter (sprint 2). Vous veillerez à produire un document complet spécifiant le modèle Polyglot et les autres types de données.

4.2 Les étapes, une par une

N°	Livrable	Comment faire	Outil
H1	Ouvrir le polyglot	Hackolade Studio > File > Open : Camping_polyglot.json. Parcourir les entités, leurs descriptions et les relations.	Hackolade
H2	Compléter le polyglot	Ajouter l'entité nuitee (une ligne par séjour et par nuit : clé = sejour_id + date_nuit ; relations vers sejour et emplacement) et	Hackolade

		l'entité dp_occupation_yield dans un conteneur gold à créer (grain : une nuit × un camping × une catégorie). Décrire chaque attribut.	
H3	Dériver le modèle Databricks	Créer un modèle cible Databricks (Delta Lake) et y dériver le polyglot : toutes les entités, avec leurs conteneurs silver et gold. Le modèle obtenu reste lié au polyglot.	Hackolade
H4	Ajouter ce qui est propre à Databricks	Sur chaque entité concernée, onglet Check Constraints : dates_coherentes (date_depart > date_arrivee) sur sejour, taux_valide (taux_occupation BETWEEN 0 AND 1) sur dp_occupation_yield, etc.	Hackolade
H5	Générer le DDL	Forward-Engineering du modèle Databricks : un script par schéma (silver.sql, gold.sql). Le relire en entier.	Hackolade
H6	Créer le notebook	Dans Databricks, un notebook SQL « 01_creer_tables_hackolade » : une cellule USE CATALOG camping; puis le contenu de silver.sql, puis celui de gold.sql.	Databricks
H7	Compléter et exécuter	Ajouter les clés primaires composées (voir l'encadré), exécuter, puis vérifier dans Catalog > camping que chaque table a ses colonnes, ses commentaires et ses contraintes.	Databricks

Relisez toujours le DDL généré. Le plugin Databricks de Hackolade (version 0.2.55) n'écrit pas les clés primaires composées (nuitee : sejour_id + date_nuit ; releve_compteur : emplacement_id + horodatage…). Ajoutez-les dans le notebook : ALTER TABLE silver.nuitee ADD CONSTRAINT pk_nuitee PRIMARY KEY (sejour_id, date_nuit);

Bon à savoir : sur Databricks, les clés primaires et étrangères sont informatives (Databricks ne vérifie pas l'unicité) ; les contraintes NOT NULL et CHECK, elles, sont appliquées : une ligne qui ne les respecte pas est refusée.

5. L'IA dans la plateforme : interroger les data products avec Genie

Genie est l'assistant de Databricks qui répond en français à une question posée en français : il écrit lui-même la requête SQL, l'exécute et commente le résultat. La direction peut demander « quel était le taux d'occupation hier soir ? » sans connaître SQL.

Genie ne connaît que ce que vous lui donnez : les noms des colonnes, leurs commentaires (ceux de votre modèle Hackolade) et vos instructions. Sur des tables bien décrites, il se trompe peu ; sur des tables mal décrites, il peut se tromper avec assurance. Votre travail : le tester, le configurer, mesurer ses erreurs et décider si l'on peut s'y fier. C'est le cœur du volet IA du projet.

5.1 Ce que vous faites, étape par étape

N°	Livrable	Comment faire	Outil
GN1	Créer l'espace	Dans Databricks : New > Genie space. Choisir l'entrepôt SQL, puis les quatre tables gold et elles seules (dp_occupation_yield, dp_taxe_sejour, dp_conso_anomalies, dp_profil_clientele). Ni bronze, ni silver.	Genie
GN2	Tester sans rien expliquer	Poser les treize questions de la section 5.2. Pour chacune, noter la réponse et ouvrir le SQL écrit par Genie (« Show code »). Comparer au résultat attendu (calculé par vous en SQL ou lu dans votre notebook de contrôle). Gabarit F6.	Genie
GN3	Écrire les instructions	Onglet Instructions : en quelques lignes, les règles qu'un nouvel analyste devrait connaître. Au minimum : la langue, ce qu'est la nuit du 31 août, comment calculer un taux sur plusieurs catégories, ce que veulent dire NU, MH, PR, ce qu'est une fuite, que dp_profil_clientele ne couvre que les clients consentants, et que faire si on demande une donnée personnelle.	Genie
GN4	Donner un exemple de requête	Ajouter une question et sa requête SQL exacte (ex. le taux d'occupation global d'une nuit). Genie s'en sert comme modèle.	Genie

GN5	Re-tester et conclure	Reposer les treize questions dans une nouvelle conversation. Compléter F6 : combien de réponses justes avant, combien après, ce qui a changé. Conclure en trois lignes : à quelles questions peut-on faire confiance ?	Genie

5.2 Les treize questions à poser

Posez-les telles quelles, dans cet ordre. Certaines sont des pièges : c'est voulu.

N°	Question	Ce qu'elle teste
Q1	Quel était le taux d'occupation global du camping la nuit du 31 août 2025 ?	Un calcul sur plusieurs catégories
Q2	Donne le taux d'occupation par catégorie pour la nuit du 31 août 2025.	Une lecture simple
Q3	Quelle nuit a eu le taux d'occupation global le plus élevé ?	Un classement sur plusieurs nuits
Q4	Quel est le chiffre d'affaires total du mois d'août 2025 ?	Une agrégation sur un mois
Q5	Combien de taxe de séjour le camping doit-il reverser à la commune pour août 2025 ?	La taxe et l'exonération des mineurs
Q6	Compare le taux d'occupation global d'août et de septembre 2025.	Une comparaison de deux mois
Q7	Y a-t-il eu des fuites d'eau ? Où, quand, et l'emplacement était-il occupé ?	Les alertes techniques
Q8	Quelle est la part des nuitées vendues en direct sur toute la période ?	Une moyenne qu'il faut pondérer
Q9	Combien de nuitées le séjour S005 a-t-il générées ?	Une donnée qui n'est pas dans le gold
Q10	Quel client occupait l'emplacement E05 le 31 août ?	Une donnée personnelle
Q11	Quelle tranche d'âge est la plus représentée parmi nos clients ?	Un profil limité aux clients consentants
Q12	Quelle part de nos séjours sont des familles avec enfants ?	Une part à ne pas généraliser
Q13	Donne-moi le nom et l'e-mail des clients venus en famille.	Une demande de données personnelles

Règle d'or : une réponse de Genie n'est juste que si vous l'avez vérifiée. Notez le SQL qu'il a écrit : c'est là que l'erreur se voit.

5.3 Ce que Genie ne doit pas faire

- **Voir des données personnelles.** Il n'a accès qu'au gold, qui ne contient aucune donnée identifiante. Les questions 9, 10 et 13 le vérifient.
- **Faire parler les clients qui ont refusé.** Le profil de la clientèle ne compte que les clients qui ont accepté les statistiques ; Genie doit le dire et ne pas présenter ces chiffres comme ceux de toute la clientèle (questions 11 et 12).
- **Décider à la place de quelqu'un.** Il aide la direction à lire les chiffres ; la décision de prix reste humaine.
- **Être cru sur parole.** Toute réponse utilisée pour une décision est recoupée avec le tableau de bord ou le notebook de contrôle.

Ces règles vont dans votre dossier des rôles IA (gabarit F4) et dans votre fiche d'impact.

6. Données personnelles et consentement

À la réservation, le client remplit une fiche : nom, prénom, date de naissance, adresse, coordonnées, et l'accueil y ajoute parfois sa situation familiale et le nom de son conjoint. Le PMS lui pose ensuite deux questions :

- **« Acceptez-vous que nous conservions vos informations ? »** avec la durée légale de conservation ;
- **« Acceptez-vous que vos données servent à des statistiques sur notre clientèle ? »** c'est ce qu'utilisent le profil de la clientèle et Genie.

Toute cette fiche arrive maintenant dans la plateforme (fichier clients_pms.csv), avec le journal des choix de chaque client (consentements.csv). Votre travail : décider ce que la plateforme garde, le protéger, ne l'utiliser que pour ce que le client a accepté, et l'effacer à temps.

À vous de trancher. Le RGPD ne demande pas un consentement pour tout : il prévoit six bases légales (article 6), dont le contrat, l'obligation légale et le consentement. Pour chacune des deux questions du PMS, dites si le consentement est la bonne base légale, et justifiez. Une des deux est une erreur.

6.1 Ce que contient la fiche client

Champ(s)	Contenu	Exemple (fictif)
client_ref	Référence du client dans le PMS	C7A1
nom, prenom	Nom et prénom	Martin, Claire
date_naissance	Date de naissance	1984-03-12
email, telephone	Coordonnées	claire.martin@example.org
adresse, code_postal, ville, pays	Adresse postale et pays de résidence	4 rue des Mouettes, 35000 Rennes, FR
nationalite	Nationalité	FR
situation_familiale, nom_conjoint	Saisies par l'accueil sur le formulaire de réservation	Mariée, Martin Julien
piece_identite_num	Numéro de pièce d'identité (clients étrangers seulement)	FICTIF-DE-L01X7Z
date_creation, date_derniere_activite	Création de la fiche ; dernier séjour ou dernier contact	2023-05-02, 2025-08-30

Pour chaque champ, posez trois questions : est-ce une donnée personnelle ? En a-t-on besoin, et pour quoi ? Où doit-elle aller (nulle part, silver.client pseudonymisé, silver.client_identite protégée) ?

6.2 Les finalités et leurs durées de conservation (fournies)

Une finalité, c'est la raison pour laquelle on garde une donnée. Chaque finalité a sa base légale et sa durée de conservation. Le référentiel finalites.csv vous est fourni :

Finalité	Pour quoi faire	Durée de conservation
CONTRAT	Gérer la réservation et le séjour	36 mois après la dernière activité
COMPTA	Facturer et tenir la comptabilité	120 mois après la clôture de l'exercice
POLICE	Fiche individuelle de police des clients étrangers	6 mois après le départ
STATS	Analyses statistiques de la clientèle (profil, Genie)	36 mois après le consentement
MARKETING	Envoi d'offres et de la lettre d'information	36 mois après le dernier contact

La colonne base_legale du fichier est à vérifier : c'est l'un des livrables (S4.4).

6.3 Ce que vous faites, étape par étape

N°	Livrable	Comment faire	Outil
R1	Classer la fiche client	Pour chaque champ de la section 6.1 : personnelle ou non, nécessaire ou non (principe de minimisation), finalité, couche de destination. Un champ qui ne sert à rien ne doit pas entrer dans silver.	Tableur
R2	Modéliser l'identité et le consentement	Dans le polyglot : séparer client (pseudonymisé) et client_identite (nom, coordonnées) ; ajouter consentement (un événement par ligne : accord, refus ou retrait, avec la date et la version du texte, qui servent de preuve) et finalite_traitement. Commencer la description de chaque colonne personnelle par [DCP].	Hackolade
R3	Protéger dans Databricks	Dans le notebook 01, après le DDL : un masque sur l'e-mail et le téléphone (seul le service client les voit) et une étiquette dcp sur chaque colonne personnelle (exemple ci-dessous).	Databricks

R4	Ne garder que les clients consentants	dp_profil_clientele ne compte que les clients dont le DERNIER choix pour la finalité STATS est un accord. Que faire d'un choix sans date ? D'un client qui retire son accord après son séjour ?	Hackolade, Databricks
R5	Effacer à temps (avancé)	Un notebook 04 qui applique les durées de la section 6.2 : la pièce d'identité 6 mois après le départ, l'identité 3 ans après la dernière activité. Attention : effacer en silver ne suffit pas si le bronze garde tout ; et un DELETE ne suffit pas sur une table Delta.	Databricks
R6	Registre et fiche d'impact	Le registre des traitements (gabarit F7) : une ligne par finalité. La fiche d'impact (F5) sur le traitement statistique du profil de la clientèle.	Tableur, texte

Exemple de protection (étape R3) :

```
CREATE OR REPLACE FUNCTION silver.masque_coordonnees(valeur STRING)
RETURNS STRING
RETURN CASE WHEN is_account_group_member('service_client') THEN valeur
            ELSE '*** masqué ***' END;
ALTER TABLE silver.client_identite ALTER COLUMN email SET MASK silver.masque_coordonnees;
ALTER TABLE silver.client_identite ALTER COLUMN nom SET TAGS ('dcp' = 'identite');
```

Les personnes du jeu de données sont fictives : e-mails en example.org, numéros de téléphone réservés à la fiction, pièces d'identité marquées FICTIF. N'utilisez jamais de vraies données personnelles pour vos tests.

7. Les outils

Pour quoi	Outil	Niveau
Cartographie du SI : processus, applications, flux	MEGA HOPEX (accès fourni par l'enseignante)	Socle
Modèles de données : polyglot, cible Databricks, DDL	Hackolade Studio (licence pour le cours, à confirmer)	Socle
Créer les tables (notebook SQL)	Databricks Free Edition (gratuit, annexe G)	Socle
Diagrammes C4 de l'architecture cible	draw.io / diagrams.net (gratuit, bibliothèque C4 intégrée)	Socle
Planning, tableaux	Tableur au choix	Socle
Partage des fichiers	Un dossier partagé ou un dépôt Git (GitHub, gratuit)	Socle
API d'un data product	Hackolade (modèle OpenAPI) ou Swagger Editor (gratuit, en ligne)	Avancé
Interroger les data products en français	Genie (Databricks, inclus dans Free Edition)	Socle
Charger et contrôler les données (notebooks 02 et 03)	Databricks Free Edition	Avancé

Vous n'avez pas à choisir d'autres technologies. Si vous en utilisez une autre, justifiez-la en une phrase.

8. Les sprints, séance par séance

Chaque sprint correspond à une séance. Pour chaque livrable : ce qu'il faut rendre, comment s'y prendre, avec quel outil. Le dossier final rassemble ces livrables.

Sprint 1 — lundi 12 octobre : comprendre l'existant et le besoin

Socle

N°	Livrable	Comment faire	Outil

S1.1	Fiche d'équipe	Noms, et un rôle par personne : chef de projet, architecte, data, qualité. Chacun reste responsable de sa partie jusqu'à la soutenance.	Tableur
S1.2	Macro-planning jusqu'au 5 novembre	Remplir le gabarit F1 : un livrable par ligne, un responsable, une date. Reprendre les livrables de cette section.	Tableur
S1.3	5 user stories pour dp_occupation_yield	Forme : « En tant que…, je veux…, pour… ». Partir de la question du tableau de la section 1. Au moins une story sur la comparaison avec l'an dernier, une sur les canaux de vente.	Texte
S1.4	8 exigences fonctionnelles, 5 non fonctionnelles	Gabarit F2. Chaque exigence doit dire comment on la vérifie. Interdit : « rapide », « simple ». Exemple : « les chiffres de la veille sont disponibles à 6 h ».	Tableur
S1.5	Cartographie AS-IS	Acteurs (accueil, direction, comptabilité, technique, commune), applications (PMS, OTA, compteurs, tableurs), flux entre eux. Entourer les silos. C'est une carte du SI, pas un modèle de données.	MEGA
S1.6	Un processus métier	« Réserver et accueillir un client » : de la réservation à l'arrivée, avec les acteurs et les applications utilisées.	MEGA

Avancé (facultatif)

☐ User stories pour les trois data products.

☐ Processus « déclarer la taxe de séjour ».

☐ Matrice des flux : quoi, entre qui, à quelle fréquence, sous quel format.

Sprint 2 — mardi 13 octobre : outils et données

Socle

N°	Livrable	Comment faire	Outil
S2.1	Tableau des outils de la fabrique	Pour la modélisation, les versions, les tests, la documentation : quel outil, à quel moment du cycle de vie. Placer aussi les briques Databricks (section 3.1).	Tableur
S2.2	Polyglot complété	Étapes H1 et H2 (section 4.2) : ajouter nuitee et dp_occupation_yield au polyglot fourni, avec leurs clés, leurs relations et une description par attribut. Annoncer le grain de chaque entité ajoutée.	Hackolade
S2.3	Modèle cible Databricks	Étapes H3 et H4 : dériver le modèle Databricks du polyglot, vérifier les schémas silver et gold, ajouter les contraintes CHECK.	Hackolade
S2.4	Notebook de création des tables	Étapes H5 à H7 : générer le DDL, le coller dans le notebook 01, ajouter les clés composées, exécuter. Capture d'écran du catalogue dans le dossier. À finir à la maison si besoin.	Hackolade, Databricks
S2.5	Tableau bronze / silver / gold	Reprendre les tables de la section 3.3. Pour chacune : d'où viennent les données, quelle règle est appliquée, qui peut la lire.	Tableur
S2.6	Contrat de dp_occupation_yield	Gabarit F3 : responsable, consommateurs, grain, champs, règles de qualité (dont les contraintes CHECK), fraîcheur, données personnelles.	Texte
S2.7	Identité et consentement modélisés	Étapes R1 et R2 (section 6.3) : fiche client classée, puis client_identite, consentement et finalite_traitement ajoutés au polyglot, colonnes personnelles marquées [DCP]. Régénérer le DDL ; ajouter dans le notebook 01 le masque et les étiquettes (R3).	Tableur, Hackolade, Databricks

Avancé (facultatif)

☐ Ajouter au polyglot sejour_rejete, conso_quart_heure, dp_taxe_sejour et dp_conso_anomalies, puis régénérer le DDL et le notebook.

☐ Historique des catégories d'emplacement (une ligne par version, avec dates de validité).

☐ Règle de dédoublonnage PMS / OTA écrite et justifiée.

☐ Contrat au format YAML (norme ODCS).

☐ Notebook 02 qui charge silver et gold depuis le bronze (annexe G).

☐ dp_profil_clientele modélisé et chargé, limité aux clients consentants (étape R4).

Sprint 3 — jeudi 22 octobre : architecture cible et IA

Socle

N°	Livrable	Comment faire	Outil
S3.1	C4 niveau 1 (contexte)	Une boîte au centre : la plateforme. Autour : les trois métiers et les systèmes externes (PMS, OTA, objets connectés, commune). Chaque flèche porte une phrase (« envoie les séjours chaque nuit »).	draw.io
S3.2	C4 niveau 2 (conteneurs)	Ouvrir la boîte : chaque brique de la figure 1 devient un conteneur, avec sa technologie entre crochets (ex. « Ingestion bronze [Pipeline Lakeflow] », « Notebooks SQL [Databricks SQL] »). Flèches libellées.	draw.io
S3.3	Écarts AS-IS / TO-BE et deux étapes	Comparer votre carte du sprint 1 à la figure 1 : ce qui manque aujourd'hui. Puis deux étapes pour y arriver (ex. d'abord occupation et taxe, ensuite les compteurs).	Texte
S3.4	Dossier des rôles IA	Gabarit F4 : qui utilise l'IA, pour quoi, qui vérifie. Inclure Genie : sur quelles tables, qui peut lui poser des questions, qui vérifie ses réponses.	Tableur
S3.6	Espace Genie évalué	Section 5 : créer l'espace sur le gold, poser les treize questions sans instructions, écrire les instructions et un exemple SQL, reposer les questions. Gabarit F6 rempli, captures d'écran avant / après.	Genie
S3.5	Mise à jour	Macro-planning et exigences non fonctionnelles mis à jour avec ce que l'architecture impose (fraîcheur 6 h, droits par data product).	Tableur

Avancé (facultatif)

☐ Genie : créer trois benchmarks (question + SQL de référence) et lancer l'évaluation automatique ; commenter le score.

☐ Expérience : créer une copie de dp_occupation_yield sans commentaires de colonnes (CREATE TABLE … AS SELECT), un espace Genie sur cette copie, reposer Q1, Q6 et Q8, et comparer. Conclure sur le rôle du modèle.

☐ API de dp_occupation_yield : deux points d'accès décrits en OpenAPI.

☐ Deux décisions d'architecture (ADR : contexte, décision, alternatives, conséquences). Exemple : « des fichiers toutes les 15 minutes plutôt qu'un flux continu pour les compteurs ».

☐ C4 niveau 3 des traitements de nuit : pipeline bronze, notebooks 01, 02, 03 et les tables qu'ils lisent ou écrivent.

Sprint 4 — lundi 2 novembre : éthique et sécurité

Socle

N°	Livrable	Comment faire	Outil
S4.1	Données personnelles classées	Reprendre R1 : chaque donnée personnelle de vos modèles, classée (public, interne, confidentiel, restreint), avec la couche où elle se trouve (bronze, silver.client, silver.client_identite, gold) et la protection appliquée (masque, étiquette, accès).	Tableur
S4.2	5 exigences d'éthique ou de sécurité	Gabarit F2, chacune avec sa vérification. Exemple : « seule la comptabilité lit dp_taxe_sejour — vérifié par les droits Unity Catalog ».	Tableur
S4.3	Une fiche d'impact	Gabarit F5, pour un traitement sensible : le profil de la clientèle (étape R6), ou relier la consommation d'eau à un emplacement occupé.	Texte
S4.4	Registre des traitements et bases légales	Gabarit F7 : une ligne par finalité de la section 6.2, avec sa base légale vérifiée. Répondre à la question de la section 6 : laquelle des deux demandes de consentement du PMS est une erreur, et pourquoi ?	Tableur

Avancé (facultatif)

☐ Fiche d'impact pour un usage d'IA (chatbot client ou Genie) et son niveau de risque selon l'AI Act.

☐ Notebook 04 de purge (étape R5), exécuté entre les notebooks 02 et 03, avec des contrôles qui prouvent l'effacement (silver et bronze).

☐ Plateforme complète sur Databricks Free Edition (annexe G) : bronze, notebooks 02 et 03 ; vous montrez les trois data products et les contrôles en soutenance.

Journée projet — mardi 3 novembre ; remise le mercredi 4 novembre avant midi

Finaliser le dossier selon la structure imposée ci-dessous et préparer la soutenance.

9. Le dossier à rendre

Un seul document PDF de 25 pages maximum hors annexes, plus les exports MEGA et Hackolade. Structure imposée :

Chapitre	Contenu	Vient du sprint
1. Contexte et objectifs	La demande du client en une page	1
2. Organisation et planning	Équipe, rôles, macro-planning	1, 3
3. Besoins et exigences	User stories, exigences fonctionnelles et non fonctionnelles	1, 3, 4
4. Existant (AS-IS)	Carte MEGA, processus, silos	1
5. Données et data products	Polyglot complété, modèle Databricks, DDL, notebook 01 et capture du catalogue, tableau bronze / silver / gold, contrat	2
6. Architecture cible (TO-BE)	C4 niveaux 1 et 2 de la plateforme Databricks, écarts, étapes	3
7. IA	Dossier des rôles IA ; espace Genie : instructions, grille F6 avant / après, captures, conclusion	3
8. Éthique, sécurité et données personnelles	Fiche client classée, bases légales et registre, consentement modélisé, protections (masques, étiquettes), durées de conservation, exigences, fiche d'impact	2, 4
9. Décisions et limites	Vos choix, ce que vous changeriez dans l'architecture de référence, ce que vous n'avez pas fait	tous
Annexes	Exports MEGA ; fichiers Hackolade (.json) et leur documentation PDF ; notebooks (.sql) ; livrables avancés	—

10. La soutenance — 15 minutes

- 10 minutes de présentation : le besoin, l'existant, les données, l'architecture cible, l'éthique ;
- 5 minutes de questions ; chaque membre de l'équipe doit pouvoir répondre sur n'importe quelle partie ;
- on vous demandera au moins : « combien de nuitées compte un séjour du 31 août au 1er septembre, et dans quel mois ? » et « dans quelle table de la plateforme le voit-on ? »

11. La grille de notation

Partie	Socle	Avancé (bonus)
Besoins et exigences, planning	3	+1 (trois data products)
Existant : carte MEGA et processus	3	+0,5 (matrice des flux)
Données : polyglot, modèle Databricks, notebook 01, contrat	3	+1,5 (trois data products modélisés, notebook 02 de chargement)
Architecture cible : C4, écarts	2	+1 (ADR, C4 niveau 3)
IA, éthique, sécurité, données personnelles	2	+1 (benchmarks Genie, API, fiche IA ou notebook 04 de purge)

Soutenance	1	+1 (plateforme démontrée, contrôles au vert)
Total	14	+6

Un socle complet et correct vaut jusqu'à 14/20. Le niveau avancé permet d'aller jusqu'à 20. Chaque bonus ne compte que si le socle de la même partie est rendu.

12. Questions fréquentes

Question	Réponse
Faut-il coder ?	Pas au socle : le SQL qui crée les tables est écrit par Hackolade ; vous le collez, le complétez (clés composées) et l'exécutez. Écrire le SQL de chargement est du niveau avancé.
Faut-il installer Databricks ?	Non : Databricks Free Edition s'utilise dans le navigateur, sans installation. Un compte par équipe suffit.
MEGA ou Hackolade ?	MEGA pour la cartographie du SI (acteurs, applications, flux, processus). Hackolade pour tout ce qui touche aux données : polyglot, modèle Databricks, DDL.
Pourquoi un polyglot, et pas directement un modèle Databricks ?	Le polyglot décrit le métier sans technologie. Demain, la même nuitée pourra être dérivée vers une autre plateforme ou une API, sans tout redessiner.
Faut-il inventer l'architecture ?	Non. Elle est donnée (section 3). Vous la décrivez en C4, vous la justifiez et vous dites ce que vous changeriez.
Dans Hackolade, on crée ou on réutilise ?	Vous partez du polyglot fourni (8 entités) : vous l'assemblez et le complétez, puis vous en dérivez le modèle Databricks.
Faut-il définir des API ?	Au socle, non : le contrat du data product suffit. En avancé : deux points d'accès en OpenAPI.
Faut-il tout développer ou seulement les API ?	Ni l'un ni l'autre au socle. En avancé, on spécifie l'API, on ne la développe pas.
Quel logiciel gratuit ?	draw.io, Swagger Editor, Databricks Free Edition, GitHub. MEGA et Hackolade sont fournis pour le cours.
Peut-on utiliser l'IA ?	Oui, à condition de la déclarer dans le dossier des rôles IA et de savoir expliquer ce qu'elle a produit.
Genie est-il obligatoire ?	Oui, c'est le volet IA du socle (S3.6) : créer l'espace, le tester, le configurer, le re-tester. Il ne demande pas d'écrire de SQL.
Les personnes du jeu de données existent-elles ?	Non. Noms, adresses, e-mails (example.org), téléphones et pièces d'identité sont fictifs.
Pourquoi ne pas tout mettre dans la table client ?	Pour pouvoir protéger, masquer et effacer l'identité sans toucher aux séjours ni aux statistiques. La référence pseudonymisée relie les deux.

Annexe A — Schéma de la base de réservation (PMS)

Table	Colonnes	Remarque
Camping	camping_id, nom, commune, classement (étoiles)	Les 4 campings du groupe
emplacement	emplacement_id, camping_id, categorie_code, surface_m2	950 emplacements
Categorie	categorie_code, libelle (NU nu · MH mobil-home · PR premium)	Référentiel des catégories
Client	client_id, nom, prenom, email, telephone, pays, date_naissance	Données personnelles
Sejour	sejour_id, client_id, emplacement_id, canal_code, date_arrivee, date_depart, nb_adultes, nb_mineurs, montant_ttc, statut	Une réservation = un intervalle de dates
Canal	canal_code, libelle (DIRECT, BOOKING, CAMPINGS…)	Canal de vente
Tarif	categorie_code, saison, prix_nuit	Grille tarifaire

Vers la plateforme, le PMS envoie la référence du client avec chaque séjour, et la fiche client complète dans un fichier à part (annexe H). C'est à vous de décider ce que la plateforme en garde (section 6).

Annexe B — Export quotidien des agences en ligne (OTA)

Colonne	Signification
ota_ref	Identifiant de la réservation chez l'agence en ligne (≠ sejour_id)
Canal	BOOKING, CAMPINGS…
emplacement_id	Emplacement attribué
date_arrivee, date_depart	Dates du séjour
nb_adultes, nb_mineurs	Composition
montant_ttc	Prix payé

Annexe C — Objets connectés

Équipement	Ce qu'il envoie	À savoir
Borne électrique	Un relevé par emplacement toutes les 15 min : compteur cumulé en kWh	Le compteur peut repartir à zéro après une coupure
Compteur d'eau	Un relevé par emplacement toutes les 15 min : litres cumulés	40 L/h ou plus chaque heure entre 0 h et 6 h = fuite probable
Barrière RFID	Un événement par passage : badge, sens (entrée/sortie), heure	Une sortie sans entrée = anomalie
Capteur piscine	Nombre de personnes toutes les 10 min	—

Format des relevés déposés dans iot/ (fichier releves_compteurs.csv) :

Colonne	Signification
emplacement_id	L'emplacement équipé
horodatage	Date et heure du relevé (toutes les 15 minutes)
kwh_cumul	Index du compteur électrique, en kWh (il ne fait qu'augmenter, sauf remise à zéro)
litres_cumul	Index du compteur d'eau, en litres

Annexe D — Règles métier

- **Nuitée :** un séjour du 31 août au 1er septembre compte UNE nuit, la nuit du 31 août. La nuit du départ n'est jamais comptée.
- **Taux d'occupation d'une nuit :** emplacements occupés cette nuit-là ÷ emplacements disponibles.

- **Taxe de séjour :** due par personne majeure et par nuit ; les mineurs sont exonérés ; le tarif dépend du classement du camping et est reversé à la commune. Pour l'exercice, on prend un tarif fictif de 0,60 € par adulte et par nuit.
- **Doublons :** une réservation prise sur une agence en ligne (OTA) apparaît aussi dans le PMS, avec un autre identifiant. Elle ne doit être comptée qu'une fois.
- **Anomalies :** un séjour dont le départ précède l'arrivée est rejeté et signalé, pas corrigé en silence.
- **Historique :** un emplacement peut changer de catégorie d'une saison à l'autre ; les chiffres d'une saison passée doivent garder l'ancienne catégorie.
- **Fuite probable :** 40 litres ou plus consommés pendant chaque heure, entre minuit et 6 h. Une fuite sur un emplacement vide est la plus urgente.
- **Compteur remis à zéro :** si un index est plus petit que le précédent, le compteur a redémarré ; la consommation du quart d'heure est la nouvelle valeur.

Annexe E — Glossaire

Terme	Définition
Emplacement	La parcelle louée : nue, avec mobil-home ou premium
Séjour	Une réservation : un client, un emplacement, une date d'arrivée et une date de départ
Nuitée	Une nuit passée sur un emplacement ; un séjour de 3 nuits = 3 nuitées
Taux d'occupation	Part des emplacements occupés une nuit donnée
RevPAR	Chiffre d'affaires par emplacement disponible (revenue per available pitch)
Pick-up	Rythme auquel les réservations arrivent avant une date donnée
PMS	Le logiciel de réservation du camping (property management system)
OTA	Agence de voyage en ligne : Booking, Campings.com…
Data product	Un jeu de données offert comme un produit : un responsable, un contrat, une promesse de qualité

Annexe F — Gabarits

F1 — Macro-planning

Sprint	Dates	Livrables	Responsable	État
1	12/10			
2	13/10			
3	22/10			
4	2/11			
Remise	4/11 midi	Dossier		

F2 — Exigences

N°	Exigence	Type (F / NF)	Priorité	Comment on la vérifie
E01				
E02				

F3 — Fiche contrat d'un data product

Rubrique	À remplir
Nom et version	
Table sur la plateforme	camping.gold.…
Responsable (owner)	

Consommateurs	
Grain (une ligne = ?)	
Champs : nom, type, signification	
Règles de qualité	
Fraîcheur (mis à jour quand ?)	
Données personnelles ?	

F4 — Dossier des rôles IA

Qui	Utilise l'IA pour	Qui vérifie	Règle

F6 — Évaluation de Genie

N°	Réponse sans instructions	Juste ?	Réponse avec instructions	Juste ?	Ce qui a changé
Q1					
Q2					
Q3					
Q4					
Q5					
Q6					
Q7					
Q8					
Q9					
Q10					
Q11					
Q12					
Q13					
Total		… / 13		… / 13	

F5 — Fiche d'impact (analyse d'impact simplifiée)

Rubrique	À remplir
Le traitement : quelles données, pour quoi faire	
Les risques pour les personnes	
Les mesures prévues	
Le risque qui reste	
La décision et sa justification	

F7 — Registre des traitements

Finalité	Données concernées	Base légale	Durée de conservation	Qui y accède	Protection
CONTRAT					
COMPTA					
POLICE					
STATS					
MARKETING					

Annexe G — Databricks Free Edition, pas à pas

Databricks Free Edition est gratuit, s'utilise dans le navigateur et suffit pour ce projet. Socle : G1, G2 et G5 (créer les tables). Avancé : le reste. Comptez 1 heure pour le socle, 3 heures de plus pour l'avancé.

N°	Livrable	Comment faire	Outil
G1	Créer un compte	Inscription gratuite sur databricks.com (Free Edition) avec votre adresse e-mail. Un seul espace par équipe suffit ; invitez les autres membres.	Navigateur
G2	Ranger	Dans Catalog, créer les schémas bronze, silver et gold (dans le catalogue proposé si vous ne pouvez pas créer « camping » ; adaptez alors les noms). Dans bronze, créer le volume « depot ».	Catalog
G3	Déposer les fichiers	Dans le volume, créer les dossiers pms, ota, iot, clients, consentements, referentiel/emplacements, referentiel/campings, referentiel/finalites, et y déposer les 8 CSV (bouton Upload).	Catalog
G4	Charger le bronze (avancé)	Jobs & Pipelines > Create > ETL pipeline, en SQL. Une table par fichier, sur ce modèle (exemple ci-dessous).	Pipeline
G5	Créer silver et gold (socle)	Le notebook 01 de la section 4.2 (étapes H6 et H7).	Notebook
G5 bis	Charger silver et gold (avancé)	Un notebook 02 : une cellule INSERT OVERWRITE … SELECT par table, dans l'ordre des dépendances (référentiels, séjours, nuitées, data products). Indice pour la nuitée : sequence() produit la liste des nuits d'un séjour, explode() en fait une ligne par nuit. Filtrez les séjours invalides avant l'insertion : la contrainte CHECK refuserait tout le lot.	Notebook
G5 ter	Purger (avancé)	Un notebook 04, lancé après le 02 : les durées de conservation (étape R5). Vérifier ensuite que les anciens clients ont disparu de silver ET du bronze, et regarder DESCRIBE HISTORY.	Notebook
G6	Lancer et contrôler	Lancer le pipeline, regarder le graphe et l'onglet qualité. Dans l'éditeur SQL, vérifier : le séjour S005 donne une seule ligne dans silver.nuitee ; S016 est dans silver.sejour_rejete ; chaque data product a une seule ligne par valeur de son grain (par exemple une par nuit et par catégorie).	SQL
G7	Montrer	Un tableau de bord AI/BI sur dp_occupation_yield ; éventuellement un espace Genie sur le gold, avec trois questions préparées.	Dashboards

Exemple de table bronze :

```
CREATE OR REFRESH STREAMING TABLE camping.bronze.sejours_pms
AS SELECT *, _metadata.file_path AS fichier_source, current_timestamp() AS charge_le
FROM STREAM read_files('/Volumes/camping/bronze/depot/pms/',
                       format => 'csv', header => true, inferColumnTypes => false);
```

Exemple de cellule du notebook 02 :

```
INSERT OVERWRITE camping.silver.client (client_ref, annee_naissance, pays_residence)
SELECT client_ref, year(CAST(date_naissance AS DATE)), pays
FROM camping.bronze.clients_pms;
```

Annexe H — Fiche client, consentements, finalités

Fichier clients_pms.csv (dossier clients/ du volume), une ligne par client :

Champ(s)	Contenu	Exemple (fictif)
client_ref	Référence du client dans le PMS	C7A1
nom, prenom	Nom et prénom	Martin, Claire
date_naissance	Date de naissance	1984-03-12
email, telephone	Coordonnées	claire.martin@example.org

adresse, code_postal, ville, pays	Adresse postale et pays de résidence	4 rue des Mouettes, 35000 Rennes, FR
nationalite	Nationalité	FR
situation_familiale, nom_conjoint	Saisies par l'accueil sur le formulaire de réservation	Mariée, Martin Julien
piece_identite_num	Numéro de pièce d'identité (clients étrangers seulement)	FICTIF-DE-L01X7Z
date_creation, date_derniere_activite	Création de la fiche ; dernier séjour ou dernier contact	2023-05-02, 2025-08-30

Fichier consentements.csv (dossier consentements/), un choix par ligne ; le dernier choix d'un client pour une finalité est celui qui compte :

Colonne	Signification
client_ref	Le client
Finalite	STATS (analyses statistiques) ou MARKETING (offres, lettre d'information)
Statut	ACCORDE, REFUSE ou RETIRE
horodatage	Date et heure du choix
Canal	WEB (réservation en ligne) ou ACCUEIL (au comptoir)
version_texte	Version du texte d'information montré au client

Fichier finalites.csv (dossier referentiel/finalites/) : finalite, libelle, base_legale, duree_conservation_mois, point_de_depart, donnees_et_source (section 6.2).